Taller 2: ETL con Apache Spark y Delta Lake en AWS EMR

Estudiante: Juan Pablo Cartagena

Carrera: Ingeniería de Sistemas - EAFIT

Fecha: Abril 2026

1. Introducción y Arquitectura

En este taller se implementó un flujo de datos bajo la arquitectura **Medallion** utilizando el ecosistema de **Amazon Web Services (AWS)**. A diferencia de entornos locales o Databricks, se utilizó **Amazon S3** como capa de almacenamiento persistente y **Amazon EMR** como motor de procesamiento distribuido.

Flujo de Datos:

- **Bronze:** Ingesta de 1,000 registros sintéticos en formato Delta.
- **Silver:** Filtrado de registros inválidos (precios < 0) y enriquecimiento temporal (año, mes, día).
- **Gold:** Generación de métricas de negocio agregadas por categoría, cliente y tiempo.

2. Configuración de Infraestructura (Evidencia AWS)

Para garantizar la alta disponibilidad del **EMR Studio** y evitar errores de capacidad en las zonas de disponibilidad, se configuró la red con múltiples subredes (us-east-1a, us-east-1b, us-east-1c).

3. Implementación del Proceso ETL

3.1. Fase Bronze y Silver

Se generaron datos de transacciones incluyendo categorías como Electrónica y Muebles. En la fase Silver, se realizó una limpieza profunda:

- Eliminación de registros con precios unitarios inválidos.
- Cálculo de total_neto aplicando porcentajes de descuento.

3.2. Gestión de Tablas Delta

Se utilizó el **Transaction Log** de Delta Lake para auditar el historial de la tabla de ventas. Superamos el reto técnico de acceder a las métricas de escritura utilizando la ruta estructurada operationMetrics.numOutputRows.

4. Resultados de Negocio (Punto 5)

E1: Producto Líder por Categoría

Utilizando funciones de ventana (Window.partitionBy), identificamos los productos con mayor volumen de ventas por categoría, asegurando una visión clara del inventario más rotado.

E2: Análisis Geográfico de Ingresos

Se consolidaron los ingresos netos por ciudad, permitiendo identificar a **Bogotá** y **Medellín** (según los datos generados) como puntos clave de venta.

E3: Tendencia Semanal (Capa Gold)

Se exportó a la capa Gold una tabla de tendencias que agrupa transacciones y ticket promedio por semana del año, facilitando análisis de estacionalidad.

5. Conclusiones

- **Escalabilidad:** El uso de EMR permite procesar grandes volúmenes de datos delegando la infraestructura a AWS.
- **Gobernanza:** Delta Lake sobre S3 proporciona ACID compliance, permitiendo hacer "Time Travel" y auditar cada cambio en los datos.
- **Optimización:** El comando OPTIMIZE ejecutado en el notebook mejoró el rendimiento de lectura al compactar archivos pequeños en S3.

A continuación las evidencias relacionadas al trabajo:

Bucket

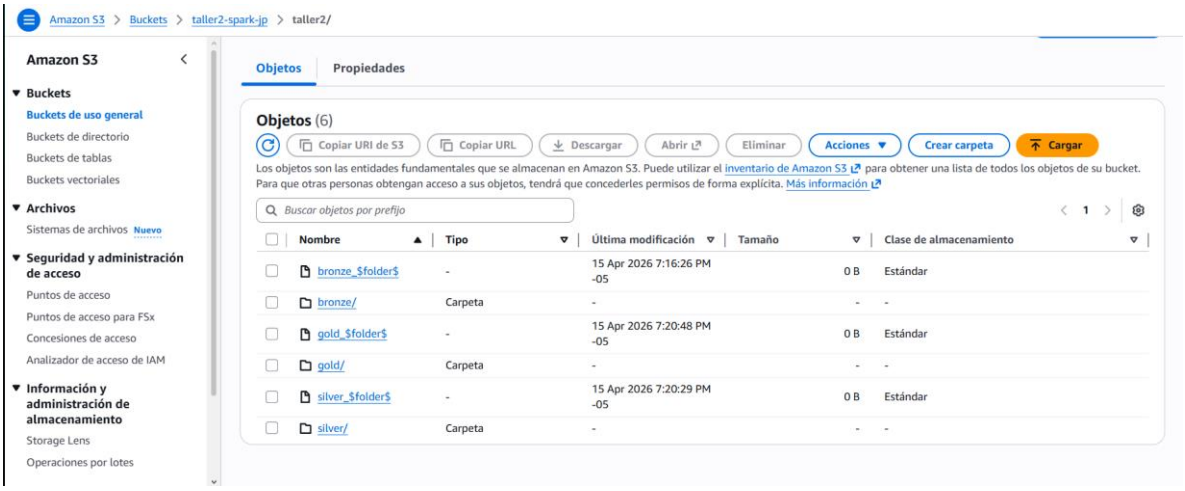
Amazon S3 > Buckets > taller2-spark-jp > taller2/
Amazon S3
Buckets
Buckets de uso general
Buckets de directorio
Buckets de tablas
Buckets vectoriales
Archivos
Sistemas de archivos Nuevo
Seguridad y administración de acceso
Puntos de acceso
Puntos de acceso para FSx
Concesiones de acceso
Analizador de acceso de IAM
Información y administración de almacenamiento
Storage Lens
Operaciones por lotes
Objetos
Propiedades
Objetos (6)
Copiar URI de S3
Copiar URL
Descargar
Abrir
Eliminar
Acciones
Crear carpeta
Cargar
Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3 para obtener una lista de todos los objetos de su bucket.
Para que otras personas obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita. Más información
Buscar objetos por prefijo
Nombre
Tipo
Última modificación
Tamaño
Clase de almacenamiento
bronze_$folder$ - 15 Apr 2026 7:16:26 PM -05 0 B Estándar
bronze/ Carpeta - - -
gold_$folder$ - 15 Apr 2026 7:20:48 PM -05 0 B Estándar
gold/ Carpeta - - -
silver_$folder$ - 15 Apr 2026 7:20:29 PM -05 0 B Estándar
silver/ Carpeta - - -

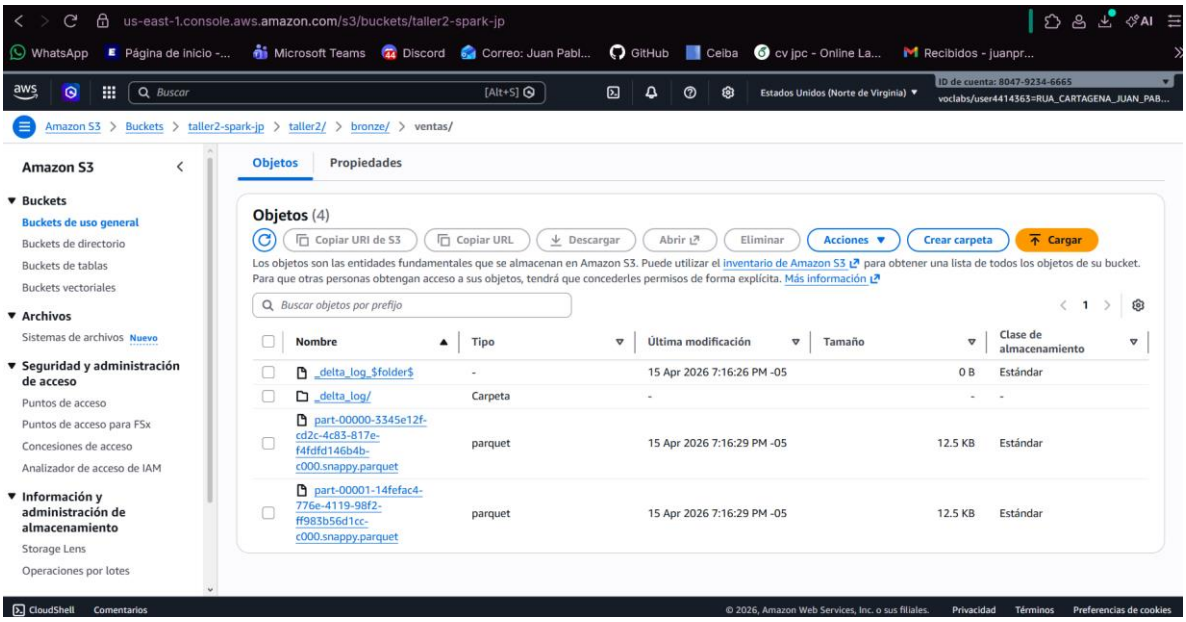
us-east-1.console.aws.amazon.com/s3/buckets/taller2-spark-jp
Amazon S3 > Buckets > taller2-spark-jp > taller2/ > bronze/ > ventas/
Objetos
Propiedades
Objetos (4)
Copiar URI de S3
Copiar URL
Descargar
Abrir
Eliminar
Acciones
Crear carpeta
Cargar
Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3 para obtener una lista de todos los objetos de su bucket.
Para que otras personas obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita. Más información
Buscar objetos por prefijo
Nombre
Tipo
Última modificación
Tamaño
Clase de almacenamiento
_delta_log_$folder$ - 15 Apr 2026 7:16:26 PM -05 0 B Estándar
_delta_log/ Carpeta - - -
part-00000-3345e12f-cd2c-4c83-817e-f4fdfd146b4b-c000.snappy.parquet parquet 15 Apr 2026 7:16:29 PM -05 12.5 KB Estándar
part-00001-14fefac4-776e-4119-98f2-ff983b56d1cc-c000.snappy.parquet parquet 15 Apr 2026 7:16:29 PM -05 12.5 KB Estándar
CloudShell
Comentarios
© 2026, Amazon Web Services, Inc. o sus filiales.
Privacidad
Términos
Preferencias de cookies

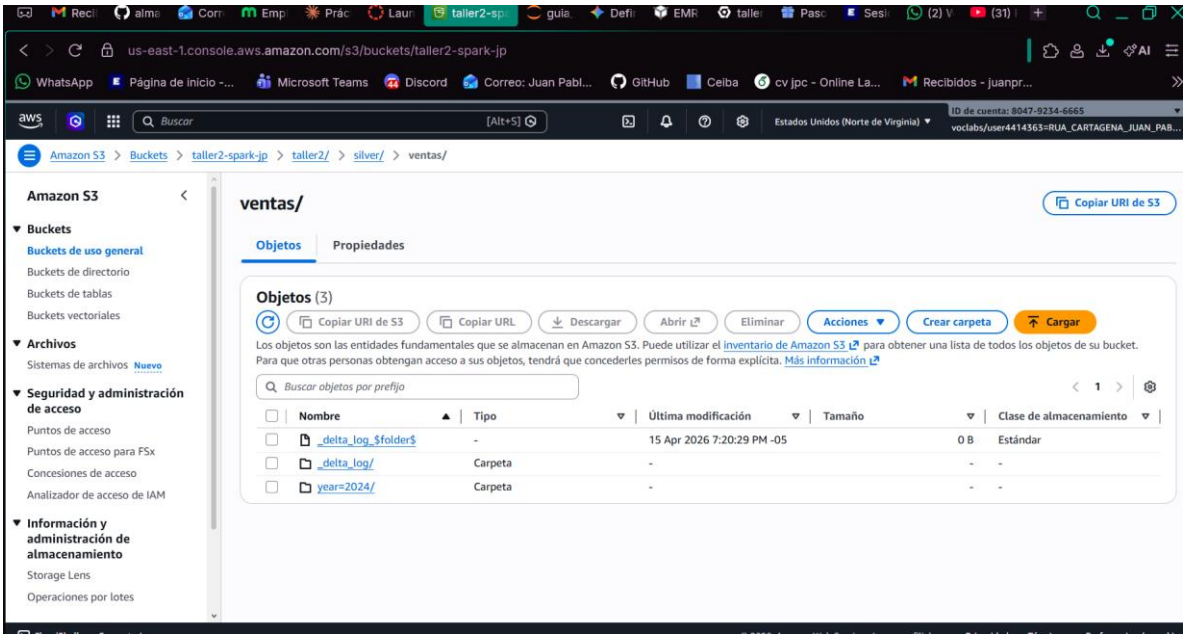
us-east-1.console.aws.amazon.com/s3/buckets/taller2-spark-jp
Amazon S3 > Buckets > taller2-spark-jp > taller2/ > silver/ > ventas/
ventas/
Copiar URI de S3
Objetos
Propiedades
Objetos (3)
Copiar URI de S3
Copiar URL
Descargar
Abrir
Eliminar
Acciones
Crear carpeta
Cargar
Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3 para obtener una lista de todos los objetos de su bucket.
Para que otras personas obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita. Más información
Buscar objetos por prefijo
Nombre
Tipo
Última modificación
Tamaño
Clase de almacenamiento
_delta_log_$folder$
-
15 Apr 2026 7:20:29 PM -05
0 B
Estándar
_delta_log/
Carpeta
year=2024/
Carpeta

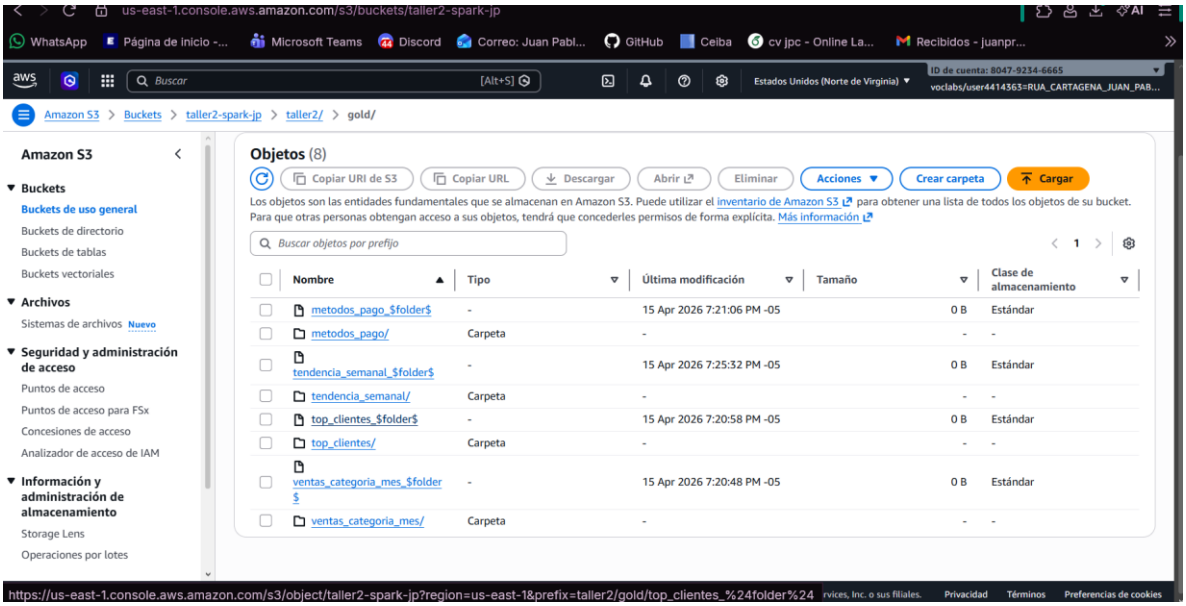
us-east-1.console.aws.amazon.com/s3/buckets/taller2-spark-jp
Amazon S3 > Buckets > taller2-spark-jp > taller2/ > gold/
Objetos (8)
Copiar URI de S3
Copiar URL
Descargar
Abrir
Eliminar
Acciones
Crear carpeta
Cargar
Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el inventario de Amazon S3 para obtener una lista de todos los objetos de su bucket.
Para que otras personas obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita. Más información
Buscar objetos por prefijo
Nombre
Tipo
Última modificación
Tamaño
Clase de almacenamiento
metodos_pago_$folder$
15 Apr 2026 7:21:06 PM -05
0 B
Estándar
metodos_pago/
Carpeta
tendencia_semanal_$folder$
15 Apr 2026 7:25:32 PM -05
0 B
Estándar
tendencia_semanal/
Carpeta
top_clientes_$folder$
15 Apr 2026 7:20:58 PM -05
0 B
Estándar
top_clientes/
Carpeta
ventas_categoria_mes_$folder$
15 Apr 2026 7:20:48 PM -05
0 B
Estándar
ventas_categoria_mes/
Carpeta
https://us-east-1.console.aws.amazon.com/s3/object/taller2-spark-jp?region=us-east-1&prefix=taller2/gold/top_clientes_%24folder%24

Cluster

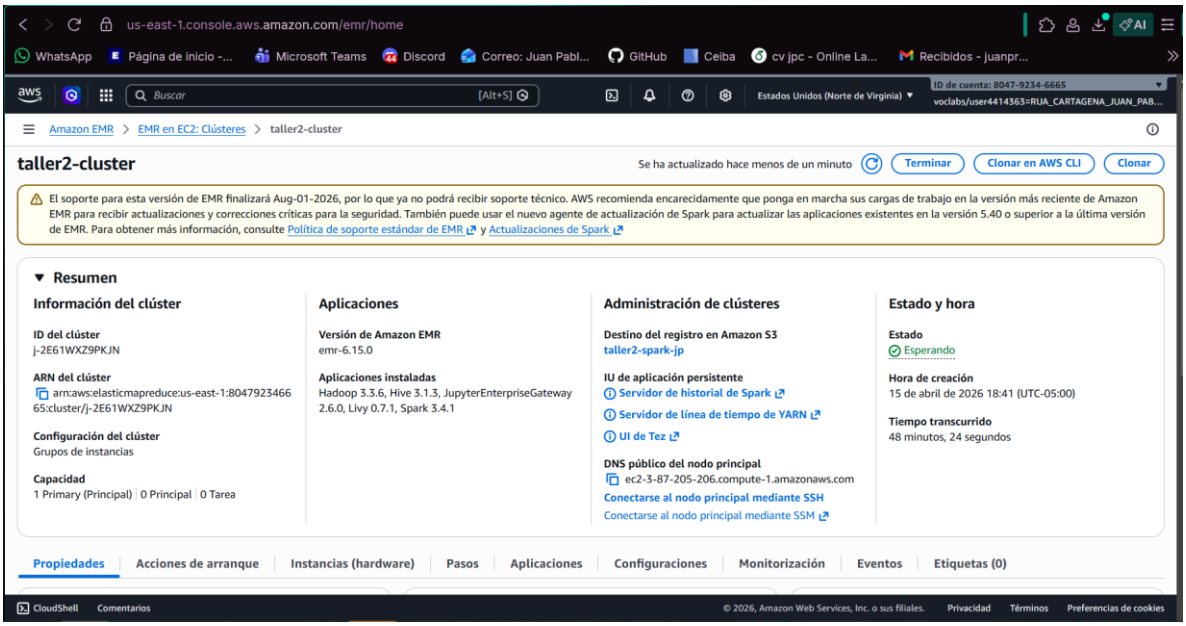
us-east-1.console.aws.amazon.com/emr/home
Amazon EMR > EMR en EC2: Clústeres > taller2-cluster
taller2-cluster
Se ha actualizado hace menos de un minuto
Terminar
Clonar en AWS CLI
Clonar
El soporte para esta versión de EMR finalizará Aug-01-2026, por lo que ya no podrá recibir soporte técnico. AWS recomienda encarecidamente que ponga en marcha sus cargas de trabajo en la versión más reciente de Amazon EMR para recibir actualizaciones y correcciones críticas para la seguridad. También puede usar el nuevo agente de actualización de Spark para actualizar las aplicaciones existentes en la versión 5.40 o superior a la última versión de EMR. Para obtener más información, consulte Política de soporte estándar de EMR y Actualizaciones de Spark
Resumen
Información del clúster
ID del clúster
j-2E61WXZ9PKJN
ARN del clúster
arn:aws:elasticmapreduce:us-east-1:804792346665:cluster/j-2E61WXZ9PKJN
Configuración del clúster
Grupos de instancias
Capacidad
1 Primary (Principal) | 0 Principal | 0 Tarea
Aplicaciones
Versión de Amazon EMR
emr-6.15.0
Aplicaciones instaladas
Hadoop 3.3.6, Hive 3.1.3, JupyterEnterpriseGateway 2.6.0, Livy 0.7.1, Spark 3.4.1
Administración de clústeres
Destino del registro en Amazon S3
taller2-spark-jp
IU de aplicación persistente
Servidor de historial de Spark
Servidor de línea de tiempo de YARN
UI de Tez
DNS público del nodo principal
ec2-3-87-205-206.compute-1.amazonaws.com
Conectarse al nodo principal mediante SSH
Conectarse al nodo principal mediante SSM
Estado y hora
Estado
Esperando
Hora de creación
15 de abril de 2026 18:41 (UTC-05:00)
Tiempo transcurrido
48 minutos, 24 segundos
Propiedades
Acciones de arranque
Instancias (hardware)
Pasos
Aplicaciones
Configuraciones
Monitorización
Eventos
Etiquetas (0)
CloudShell
Comentarios
© 2026, Amazon Web Services, Inc. o sus filiales.
Privacidad
Términos
Preferencias de cookies

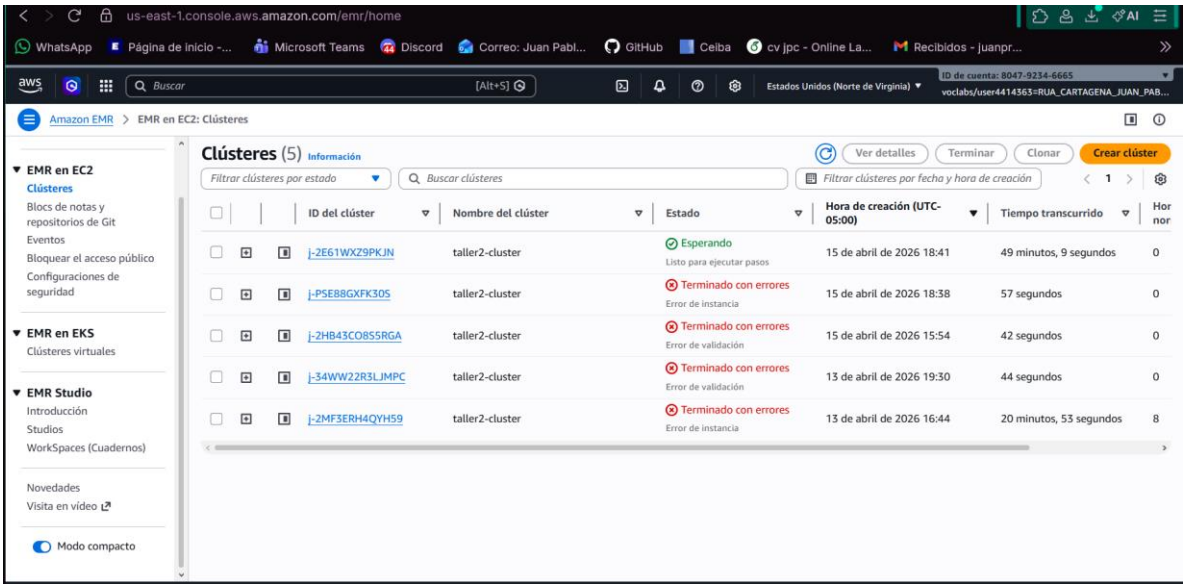
us-east-1.console.aws.amazon.com/emr/home
Amazon EMR > EMR en EC2: Clústeres
EMR en EC2
Clústeres
Blocs de notas y repositorios de Git
Eventos
Bloquear el acceso público
Configuraciones de seguridad
EMR en EKS
Clústeres virtuales
EMR Studio
Introducción
Studios
WorkSpaces (Cuadernos)
Novedades
Visita en vídeo
Modo compacto
Clústeres (5) Información
Ver detalles
Terminar
Clonar
Crear clúster
Filtrar clústeres por estado
Buscar clústeres
Filtrar clústeres por fecha y hora de creación
ID del clúster
Nombre del clúster
Estado
Hora de creación (UTC-05:00)
Tiempo transcurrido
j-2E61WXZ9PKJN taller2-cluster Esperando Listo para ejecutar pasos 15 de abril de 2026 18:41 49 minutos, 9 segundos 0
j-P5E88GXFK30S taller2-cluster Terminado con errores Error de instancia 15 de abril de 2026 18:38 57 segundos 0
j-2HB43CO8S5RGA taller2-cluster Terminado con errores Error de validación 15 de abril de 2026 15:54 42 segundos 0
j-34WW22R3LJMPC taller2-cluster Terminado con errores Error de validación 13 de abril de 2026 19:30 44 segundos 0
j-2MF3ERH4QYH59 taller2-cluster Terminado con errores Error de instancia 13 de abril de 2026 16:44 20 minutos, 53 segundos 8

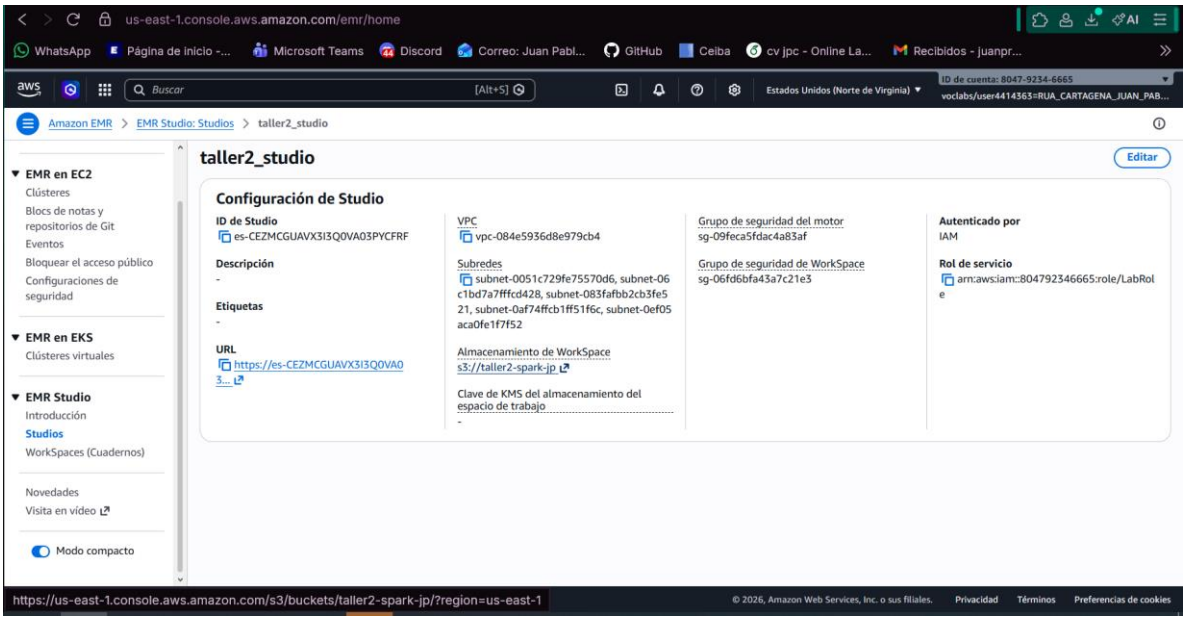
us-east-1.console.aws.amazon.com/emr/home
Amazon EMR > EMR Studio: Studios > taller2_studio
EMR en EC2
Clústeres
Blocs de notas y repositorios de Git
Eventos
Bloquear el acceso público
Configuraciones de seguridad
EMR en EKS
Clústeres virtuales
EMR Studio
Introducción
Studios
WorkSpaces (Cuadernos)
Novedades
Visita en vídeo
Modo compacto
taller2_studio
Editar
Configuración de Studio
ID de Studio
es-CEZMCGUAVX3I3Q0VA03PYCFRF
Descripción
-
Etiquetas
-
URL
https://es-CEZMCGUAVX3I3Q0VA03...
VPC
vpc-084e5936d8e979cb4
Subredes
subnet-0051c729fe75570d6, subnet-06c1bd7a7fffcd428, subnet-083fafbb2cb3fe521, subnet-0af74ffcb1ff51f6c, subnet-0ef05aca0fe1f7f52
Almacenamiento de WorkSpace
s3://taller2-spark-jp
Clave de KMS del almacenamiento del espacio de trabajo
-
Grupo de seguridad del motor
sg-09feca5fdac4a83af
Grupo de seguridad de WorkSpace
sg-06fd6bfa43a7c21e3
Autenticado por
IAM
Rol de servicio
arn:aws:iam::804792346665:role/LabRole
https://us-east-1.console.aws.amazon.com/s3/buckets/taller2-spark-jp/?region=us-east-1
© 2026, Amazon Web Services, Inc. o sus filiales.
Privacidad
Términos
Preferencias de cookies

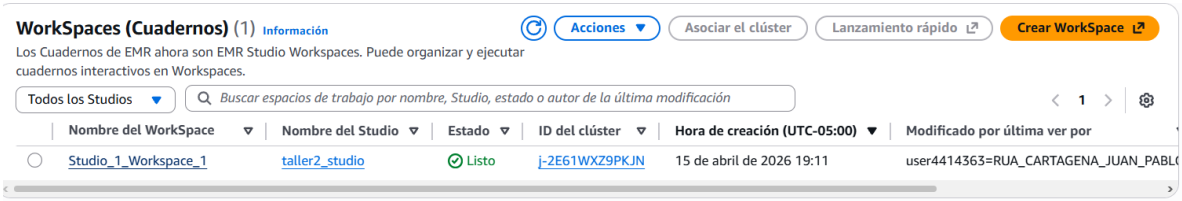
WorkSpaces (Cuadernos) (1) Información
Los Cuadernos de EMR ahora son EMR Studio Workspaces. Puede organizar y ejecutar cuadernos interactivos en Workspaces.
Acciones
Asociar el clúster
Lanzamiento rápido
Crear WorkSpace
Todos los Studios
Buscar espacios de trabajo por nombre, Studio, estado o autor de la última modificación
Nombre del WorkSpace
Nombre del Studio
Estado
ID del clúster
Hora de creación (UTC-05:00)
Modificado por última ver por
Studio_1_Workspace_1
taller2_studio
Listo
j-2E61WXZ9PKJN
15 de abril de 2026 19:11
user4414363=RUA_CARTAGENA_JUAN_PABL

Jupyter

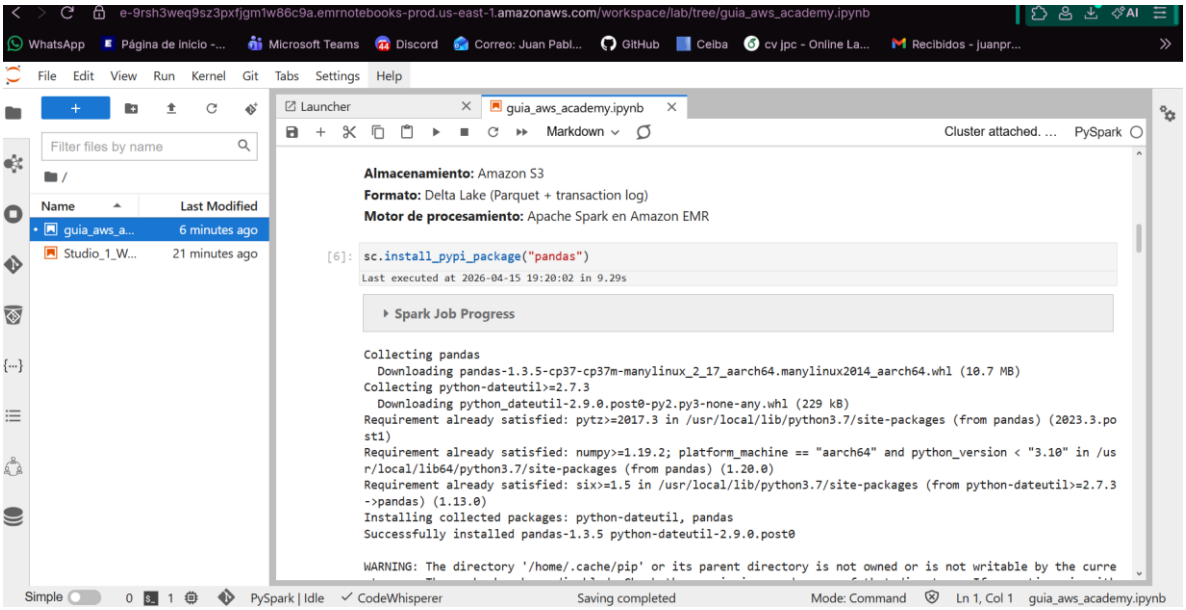
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Filter files by name
Name
Last Modified
guia_aws_a...
6 minutes ago
Studio_1_W...
21 minutes ago
Almacenamiento: Amazon S3
Formato: Delta Lake (Parquet + transaction log)
Motor de procesamiento: Apache Spark en Amazon EMR
[6]: sc.install_pypi_package("pandas")
Last executed at 2026-04-15 19:20:02 in 9.29s
Spark Job Progress
Collecting pandas
Downloading pandas-1.3.5-cp37-cp37m-manylinux_2_17_aarch64.manylinux2014_aarch64.whl (10.7 MB)
Collecting python-dateutil>=2.7.3
Downloading python_dateutil-2.9.0.post0-py2.py3-none-any.whl (229 kB)
Requirement already satisfied: pytz>=2017.3 in /usr/local/lib/python3.7/site-packages (from pandas) (2023.3.post1)
Requirement already satisfied: numpy>=1.19.2; platform_machine == "aarch64" and python_version < "3.10" in /usr/local/lib64/python3.7/site-packages (from pandas) (1.20.0)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.7/site-packages (from python-dateutil>=2.7.3->pandas) (1.13.0)
Installing collected packages: python-dateutil, pandas
Successfully installed pandas-1.3.5 python-dateutil-2.9.0.post0
WARNING: The directory '/home/.cache/pip' or its parent directory is not owned or is not writable by the curre
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

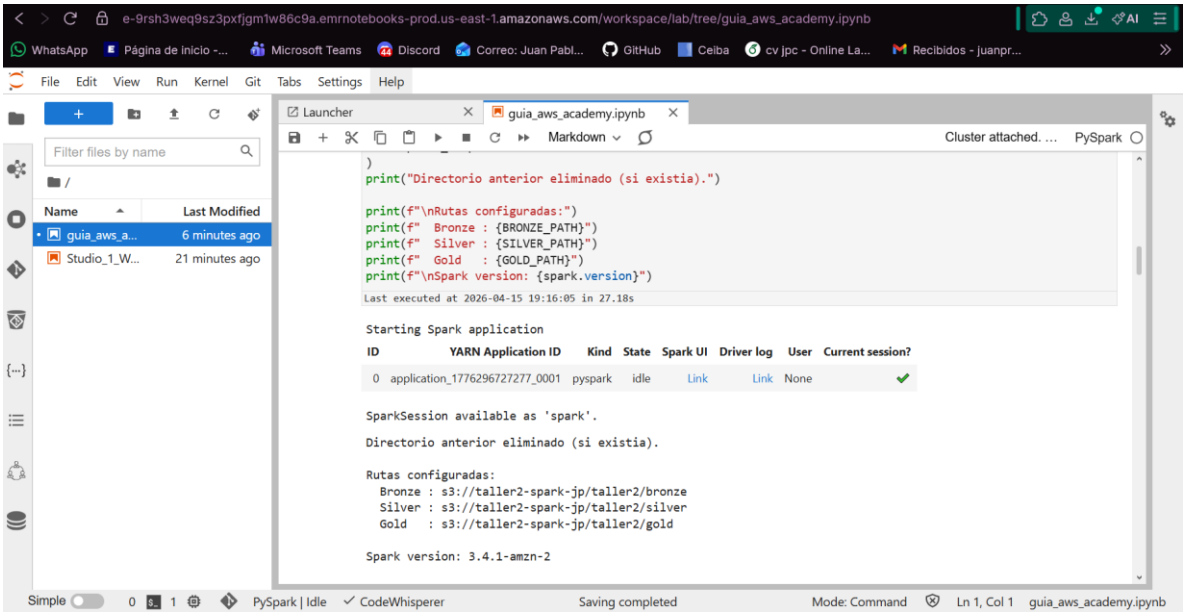
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Filter files by name
Name
Last Modified
guia_aws_a...
6 minutes ago
Studio_1_W...
21 minutes ago
)
print("Directorio anterior eliminado (si existia).")
print(f"\nRutas configuradas:")
print(f" Bronze : {BRONZE_PATH}")
print(f" Silver : {SILVER_PATH}")
print(f" Gold : {GOLD_PATH}")
print(f"\nSpark version: {spark.version}")
Last executed at 2026-04-15 19:16:05 in 27.18s
Starting Spark application
ID YARN Application ID Kind State Spark UI Driver log User Current session?
0 application_1776296727277_0001 pyspark idle Link Link None
SparkSession available as 'spark'.
Directorio anterior eliminado (si existia).
Rutas configuradas:
Bronze : s3://taller2-spark-jp/taller2/bronze
Silver : s3://taller2-spark-jp/taller2/silver
Gold : s3://taller2-spark-jp/taller2/gold
Spark version: 3.4.1-amzn-2
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

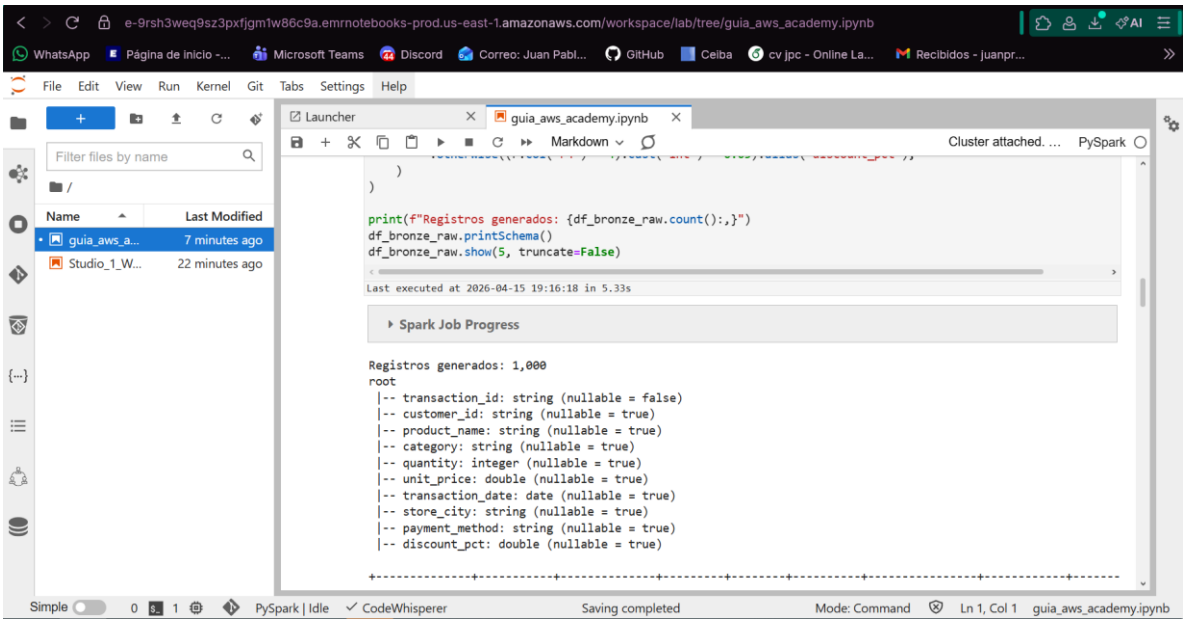
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Filter files by name
Name
Last Modified
guia_aws_a...
7 minutes ago
Studio_1_W...
22 minutes ago
print(f"Registros generados: {df_bronze_raw.count():,}")
df_bronze_raw.printSchema()
df_bronze_raw.show(5, truncate=False)
Last executed at 2026-04-15 19:16:18 in 5.33s
Spark Job Progress
Registros generados: 1,000
root
|-- transaction_id: string (nullable = false)
|-- customer_id: string (nullable = true)
|-- product_name: string (nullable = true)
|-- category: string (nullable = true)
|-- quantity: integer (nullable = true)
|-- unit_price: double (nullable = true)
|-- transaction_date: date (nullable = true)
|-- store_city: string (nullable = true)
|-- payment_method: string (nullable = true)
|-- discount_pct: double (nullable = true)
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

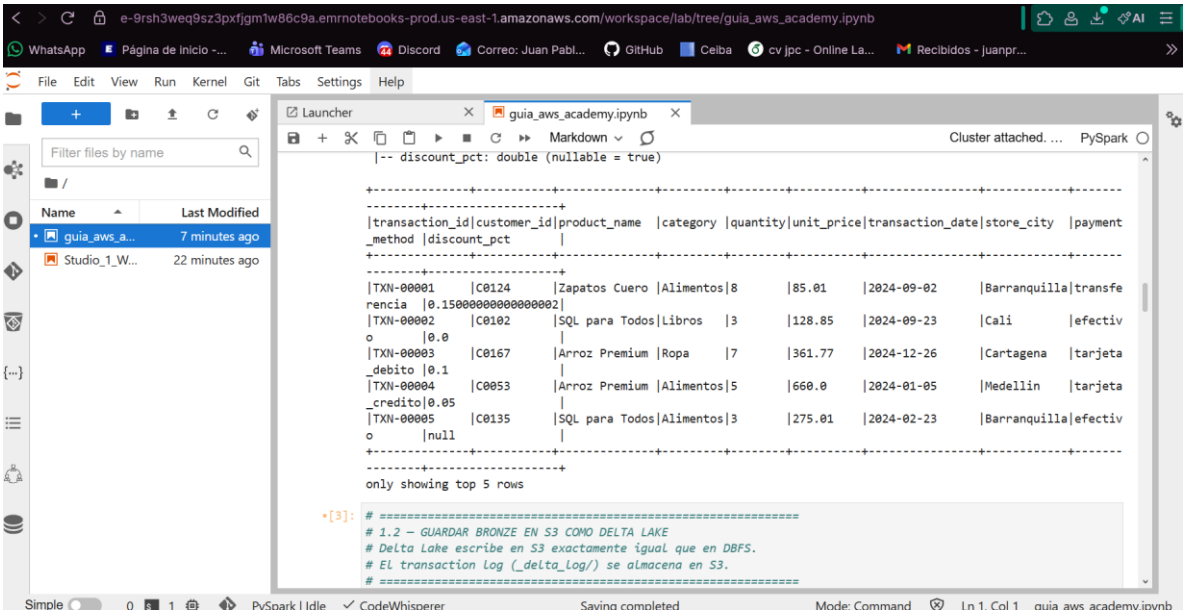
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
|-- discount_pct: double (nullable = true)
TXN-00001	C0124	Zapatos Cuero	Alimentos	8	85.01	2024-09-02	Barranquilla	transferencia	0.15000000000000002
TXN-00002	C0102	SQL para Todos	Libros	3	128.85	2024-09-23	Cali	efectivo	0.0
TXN-00003	C0167	Arroz Premium	Ropa	7	361.77	2024-12-26	Cartagena	tarjeta_debito	0.1
TXN-00004	C0053	Arroz Premium	Alimentos	5	660.0	2024-01-05	Medellin	tarjeta_credito	0.05
TXN-00005	C0135	SQL para Todos	Alimentos	3	275.01	2024-02-23	Barranquilla	efectivo	null
only showing top 5 rows
[3]:
==========
1.2 — GUARDAR BRONZE EN S3 COMO DELTA LAKE
Delta Lake escribe en S3 exactamente igual que en DBFS.
El transaction log (_delta_log/) se almacena en S3.
==========
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

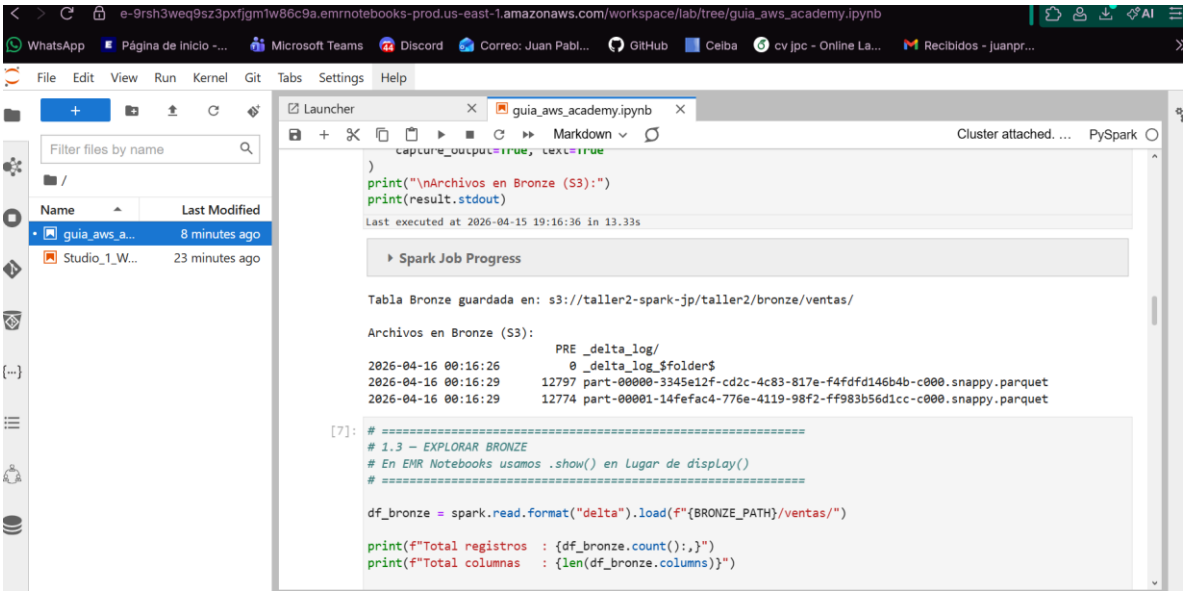
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Filter files by name
Name
Last Modified
guia_aws_a...
8 minutes ago
Studio_1_W...
23 minutes ago
print("\nArchivos en Bronze (S3):")
print(result.stdout)
Last executed at 2026-04-15 19:16:36 in 13.33s
Spark Job Progress
Tabla Bronze guardada en: s3://taller2-spark-jp/taller2/bronze/ventas/
Archivos en Bronze (S3):
PRE _delta_log/
2026-04-16 00:16:26 0 _delta_log_$folder$
2026-04-16 00:16:29 12797 part-00000-3345e12f-cd2c-4c83-817e-f4fdfd146b4b-c000.snappy.parquet
2026-04-16 00:16:29 12774 part-00001-14fefac4-776e-4119-98f2-ff983b56d1cc-c000.snappy.parquet
[7]:
# 1.3 — EXPLORAR BRONZE
# En EMR Notebooks usamos .show() en lugar de display()
df_bronze = spark.read.format("delta").load(f"{BRONZE_PATH}/ventas/")
print(f"Total registros : {df_bronze.count():,}")
print(f"Total columnas : {len(df_bronze.columns)}")

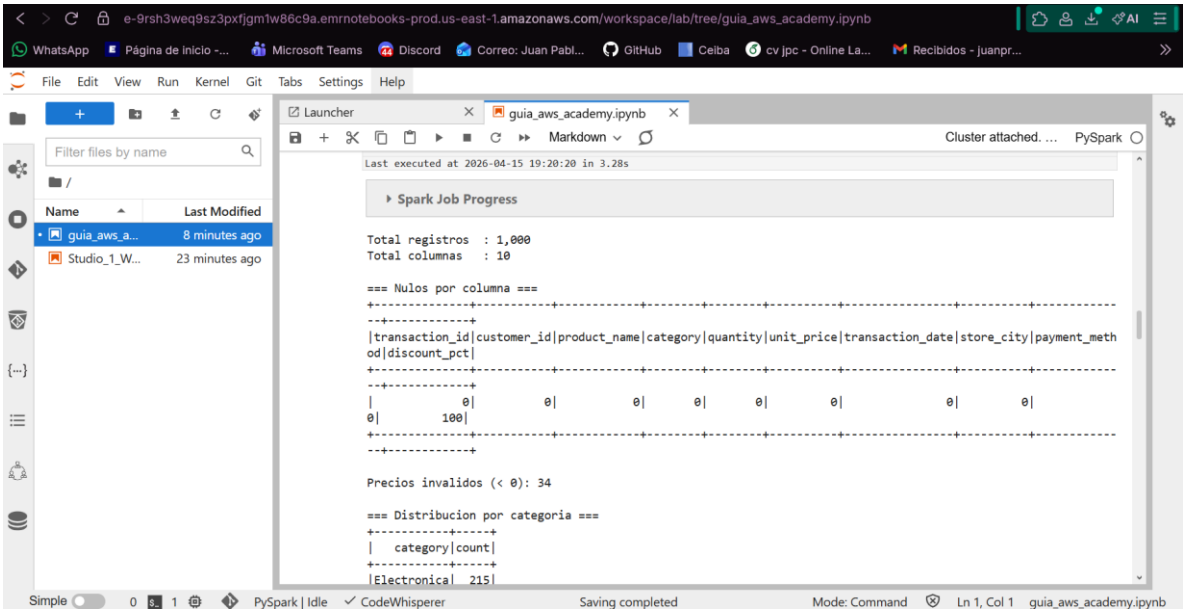
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Filter files by name
Name
Last Modified
guia_aws_a...
8 minutes ago
Studio_1_W...
23 minutes ago
Last executed at 2026-04-15 19:20:20 in 3.28s
Spark Job Progress
Total registros : 1,000
Total columnas : 10
=== Nulos por columna ===
|transaction_id|customer_id|product_name|category|quantity|unit_price|transaction_date|store_city|payment_method|discount_pct|
| 0| 0| 0| 0| 0| 0| 0| 0| 0| 100|
Precios invalidos (< 0): 34
=== Distribucion por categoria ===
| category|count|
|Electronica| 215|
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

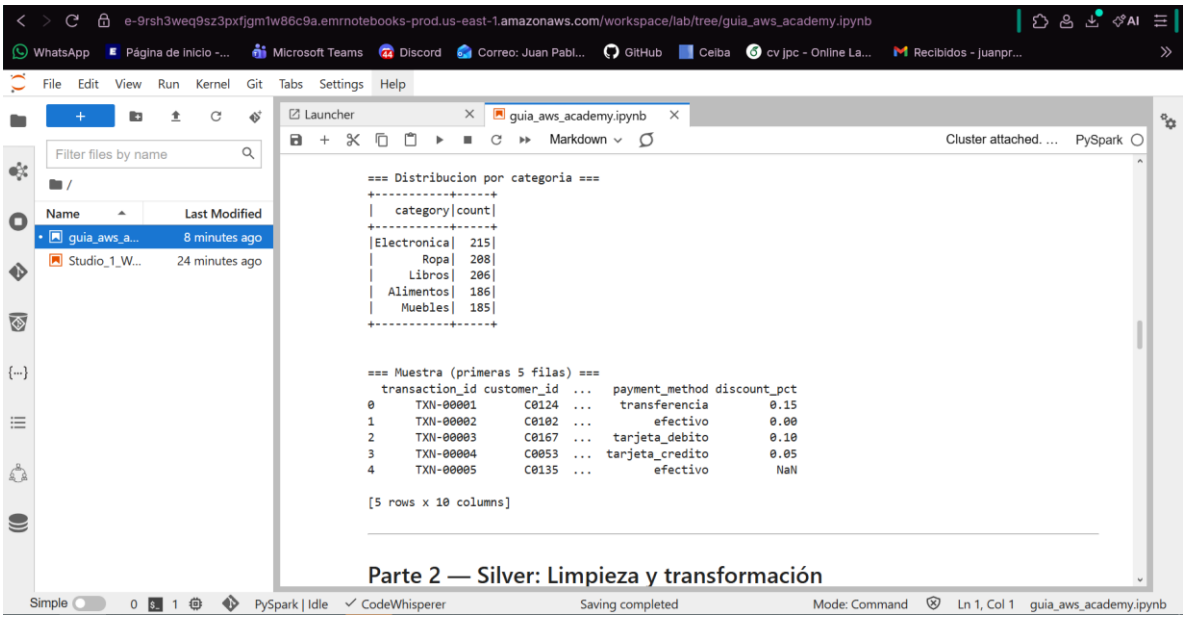
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Name
Last Modified
guia_aws_a...
8 minutes ago
Studio_1_W...
24 minutes ago
=== Distribucion por categoria ===
+-----+-----+
| category|count|
+-----+-----+
|Electronica| 215|
Ropa	208
Libros	206
Alimentos	186
Muebles	185
+-----+-----+
=== Muestra (primeras 5 filas) ===
transaction_id customer_id ... payment_method discount_pct
0 TXN-00001 C0124 ... transferencia 0.15
1 TXN-00002 C0102 ... efectivo 0.00
2 TXN-00003 C0167 ... tarjeta_debito 0.10
3 TXN-00004 C0053 ... tarjeta_credito 0.05
4 TXN-00005 C0135 ... efectivo NaN
[5 rows x 10 columns]
Parte 2 — Silver: Limpieza y transformación
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

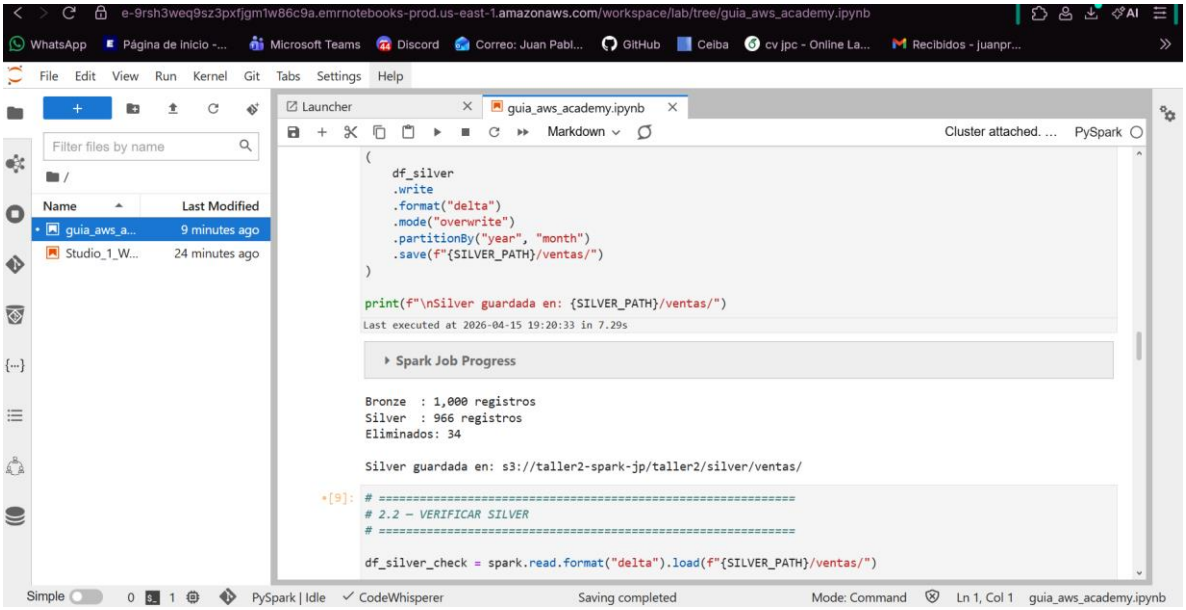
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Name
Last Modified
guia_aws_a...
9 minutes ago
Studio_1_W...
24 minutes ago
(df_silver .write .format("delta") .mode("overwrite") .partitionBy("year", "month") .save(f"{SILVER_PATH}/ventas/"))
print(f"\nSilver guardada en: {SILVER_PATH}/ventas/")
Last executed at 2026-04-15 19:20:33 in 7.29s
Spark Job Progress
Bronze : 1,000 registros
Silver : 966 registros
Eliminados: 34
Silver guardada en: s3://taller2-spark-jp/taller2/silver/ventas/
*[9]:
# 2.2 — VERIFICAR SILVER
df_silver_check = spark.read.format("delta").load(f"{SILVER_PATH}/ventas/")
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

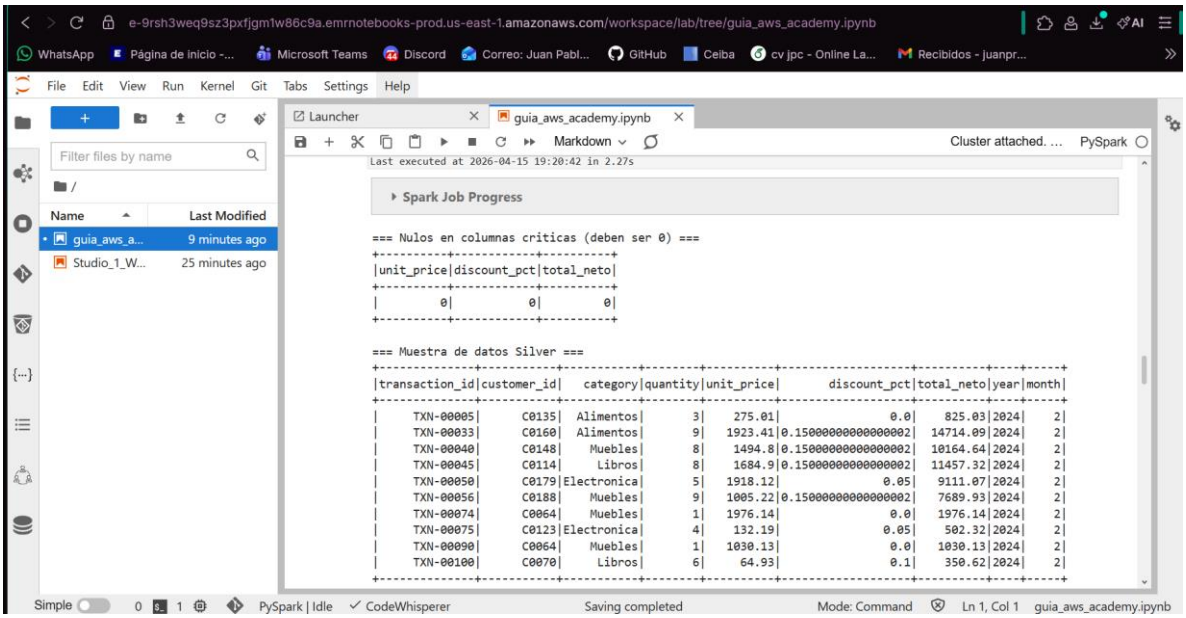
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Last executed at 2026-04-15 19:20:42 in 2.27s
Spark Job Progress
=== Nulos en columnas criticas (deben ser 0) ===
|unit_price|discount_pct|total_neto|
| 0| 0| 0|
=== Muestra de datos Silver ===
transaction_id	customer_id	category	quantity	unit_price	discount_pct	total_neto	year	month
TXN-00005	C0135	Alimentos	3	275.01	0.0	825.03	2024	2
TXN-00033	C0160	Alimentos	9	1923.41	0.15000000000000002	14714.09	2024	2
TXN-00040	C0148	Muebles	8	1494.8	0.15000000000000002	10164.64	2024	2
TXN-00045	C0114	Libros	8	1684.9	0.15000000000000002	11457.32	2024	2
TXN-00050	C0179	Electronica	5	1918.12	0.05	9111.07	2024	2
TXN-00056	C0188	Muebles	9	1005.22	0.15000000000000002	7689.93	2024	2
TXN-00074	C0064	Muebles	1	1976.14	0.0	1976.14	2024	2
TXN-00075	C0123	Electronica	4	132.19	0.05	502.32	2024	2
TXN-00090	C0064	Muebles	1	1030.13	0.0	1030.13	2024	2
TXN-00100	C0070	Libros	6	64.93	0.1	350.62	2024	2
Name
Last Modified
guia_aws_a...
9 minutes ago
Studio_1_W...
25 minutes ago
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

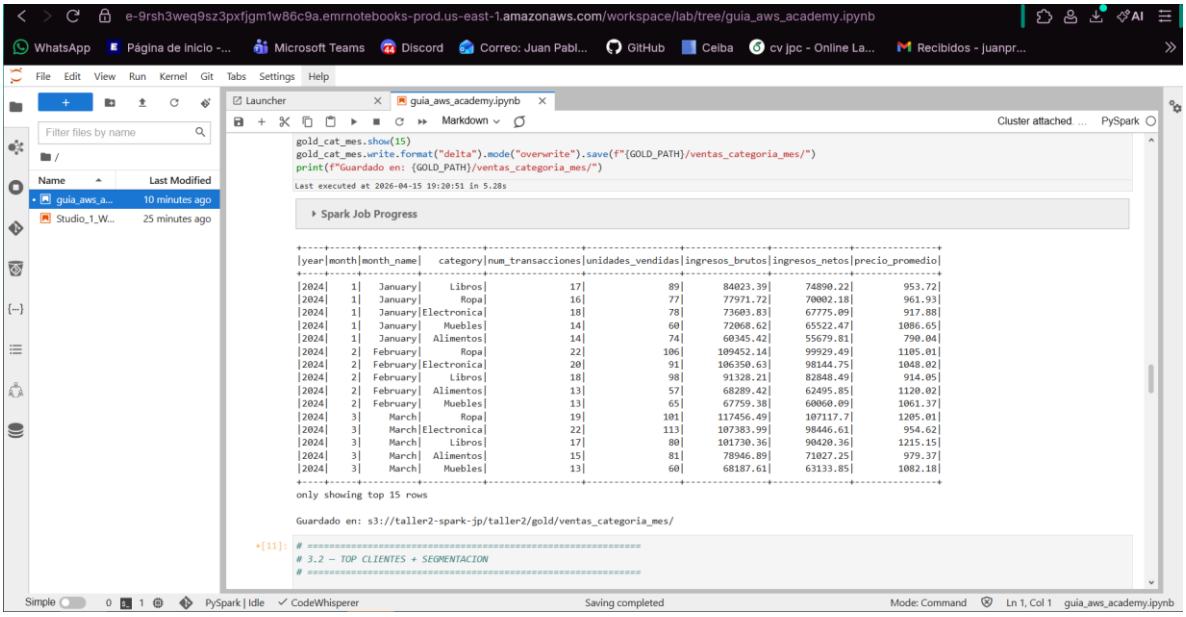
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
gold_cat_mes.show(15)
gold_cat_mes.write.format("delta").mode("overwrite").save(f"{GOLD_PATH}/ventas_categoria_mes/")
print(f"Guardado en: {GOLD_PATH}/ventas_categoria_mes/")
Last executed at 2026-04-15 19:20:51 in 5.28s
Spark Job Progress
|year|month|month_name| category|num_transacciones|unidades_vendidas|ingresos_brutos|ingresos_netos|precio_promedio|
|2024| 1| January| Libros| 17| 89| 84023.39| 74890.22| 953.72|
|2024| 1| January| Ropa| 16| 77| 77971.72| 70002.18| 961.93|
|2024| 1| January|Electronica| 18| 78| 73603.83| 67775.09| 917.88|
|2024| 1| January| Muebles| 14| 60| 72068.62| 65522.47| 1086.65|
|2024| 1| January| Alimentos| 14| 74| 60345.42| 55679.81| 790.04|
|2024| 2| February| Ropa| 22| 106| 109452.14| 99929.49| 1105.01|
|2024| 2| February|Electronica| 20| 91| 106350.63| 98144.75| 1048.02|
|2024| 2| February| Libros| 18| 98| 91328.21| 82848.49| 914.05|
|2024| 2| February| Alimentos| 13| 57| 68289.42| 62495.85| 1120.02|
|2024| 2| February| Muebles| 13| 65| 67759.38| 60060.09| 1061.37|
|2024| 3| March| Ropa| 19| 101| 117456.49| 107117.7| 1205.01|
|2024| 3| March|Electronica| 22| 113| 107383.99| 98446.61| 954.62|
|2024| 3| March| Libros| 17| 80| 101730.36| 90420.36| 1215.15|
|2024| 3| March| Alimentos| 15| 81| 78946.89| 71027.25| 979.37|
|2024| 3| March| Muebles| 13| 60| 68187.61| 63133.85| 1082.18|
only showing top 15 rows
Guardado en: s3://taller2-spark-jp/taller2/gold/ventas_categoria_mes/
[11]:
3.2 — TOP CLIENTES + SEGMENTACION
Name
Last Modified
guia_aws_a...
10 minutes ago
Studio_1_W...
25 minutes ago
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb

Spark Job Progress

```
=== Top 15 clientes ===
+-----------+----------+-----------+-------------+---------------------+--------+
|customer_id|num_compras|gasto_total|gasto_promedio|categorias_distintas|segmento|
+-----------+----------+-----------+-------------+---------------------+--------+
|      C0200|        13|   89411.26|      6877.79|                    5|     VIP|
|      C0044|        10|   70668.57|      7066.86|                    4|     VIP|
|      C0149|         9|   67869.59|      7541.07|                    4|     VIP|
|      C0130|        13|   62815.21|      4831.94|                    5|     VIP|
|      C0133|         9|   61700.89|      6855.65|                    4|     VIP|
|      C0100|         9|   54385.39|      6042.82|                    5|     VIP|
|      C0127|         8|   54207.71|      6775.96|                    4|     VIP|
|      C0155|         9|   52881.79|      5875.75|                    3|     VIP|
|      C0016|         6|   52308.99|      8718.17|                    3|     VIP|
|      C0140|         8|   51041.69|      6380.21|                    2|     VIP|
|      C0049|         5|   50852.57|     10170.51|                    4|     VIP|
|      C0051|         9|   50405.48|      5600.61|                    4|     VIP|
|      C0036|         9|   47958.09|      5328.68|                    4|     VIP|
|      C0058|         6|    46851.0|       7808.5|                    4|     VIP|
|      C0032|         9|   46187.16|      5131.91|                    5|     VIP|
+-----------+----------+-----------+-------------+---------------------+--------+
only showing top 15 rows

=== Distribucion de segmentos ===
+--------+-----+
|segmento|count|
+--------+-----+
|     VIP|  186|
| Premium|   11|
| Regular|    2|
+--------+-----+

Guardado en: s3://taller2-spark-jp/taller2/gold/top_clientes/
```

e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb

```
    ORDER BY ingresos_netos DESC
""")

gold_pagos.show()
gold_pagos.write.format("delta").mode("overwrite").save(f"{GOLD_PATH}/metodos_pago/")
print(f"Guardado en: {GOLD_PATH}/metodos_pago/")
```

Last executed at 2026-04-15 19:21:09 in 5.28s

Spark Job Progress

```
+---------------+----------------+-------------+---------------+----------------------+
| payment_method|num_transacciones|ingresos_netos|ticket_promedio|descuento_promedio_pct|
+---------------+----------------+-------------+---------------+----------------------+
|  transferencia|             263|   1280346.03|        4868.24|                   6.7|
| tarjeta_debito|             231|   1162463.82|        5032.31|                   6.5|
|tarjeta_credito|             235|    1078160.7|        4587.92|                   6.6|
|       efectivo|             237|  1068834.03|        4509.85|                   7.1|
+---------------+----------------+-------------+---------------+----------------------+

Guardado en: s3://taller2-spark-jp/taller2/gold/metodos_pago/
```

Parte 4 — Delta Lake: Capacidades avanzadas

Delta Lake es un **formato de tabla abierto** que funciona de forma idéntica sobre S3 que sobre DBFS.
El transaction log (`_delta_log/`) se almacena directamente en el bucket S3.

[14]:
```
# ============================================================
# 4.1 — TRANSACTION LOG: DESCRIBE HISTORY (CORREGIDO)
# ============================================================
```

e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb

```
    ["aws", "s3", "ls", f"{SILVER_PATH}/ventas/_delta_log/"],
    capture_output=True, text=True
)
print("\nArchivos del transaction log en S3:")
print(result.stdout)
```

Last executed at 2026-04-15 19:22:49 in 1.26s

Spark Job Progress

```
=== Historial de la tabla Silver ===
+-------+-------------------+---------+-------------+
|version|timestamp          |operation|numOutputRows|
+-------+-------------------+---------+-------------+
|0      |2026-04-16 00:20:32|WRITE    |966          |
+-------+-------------------+---------+-------------+


Archivos del transaction log en S3:
2026-04-16 00:20:32      38241 00000000000000000000.json
```

[15]:
```
# ============================================================
# 4.2 — CREAR NUEVA VERSION CON APPEND
# ============================================================

df_nuevos = df_silver.limit(50).withColumn("processed_at", F.current_timestamp())

(
    df_nuevos
    .write
    .format("delta")
    .mode("append")
    .save(f"{SILVER_PATH}/ventas/")
)
```

e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb

```
    .format("delta")
    .mode("append")
    .save(f"{SILVER_PATH}/ventas/")
)

print("Append completado. Versiones disponibles:")
silver_dt.history().select("version", "timestamp", "operation").show()
```

Last executed at 2026-04-15 19:22:55 in 3.27s

Spark Job Progress

```
Append completado. Versiones disponibles:
+-------+-------------------+---------+
|version|          timestamp|operation|
+-------+-------------------+---------+
|      1|2026-04-16 00:22:54|    WRITE|
|      0|2026-04-16 00:20:32|    WRITE|
+-------+-------------------+---------+
```

[16]:
```
# ============================================================
# 4.3 — TIME TRAVEL: LEER VERSION ANTERIOR
# Funciona igual en S3 que en DBFS gracias al transaction log
# ============================================================

df_actual = spark.read.format("delta").load(f"{SILVER_PATH}/ventas/")

df_v0 = (
    spark.read
    .format("delta")
    .option("versionAsOf", 0)
    .load(f"{SILVER_PATH}/ventas/")
)
```

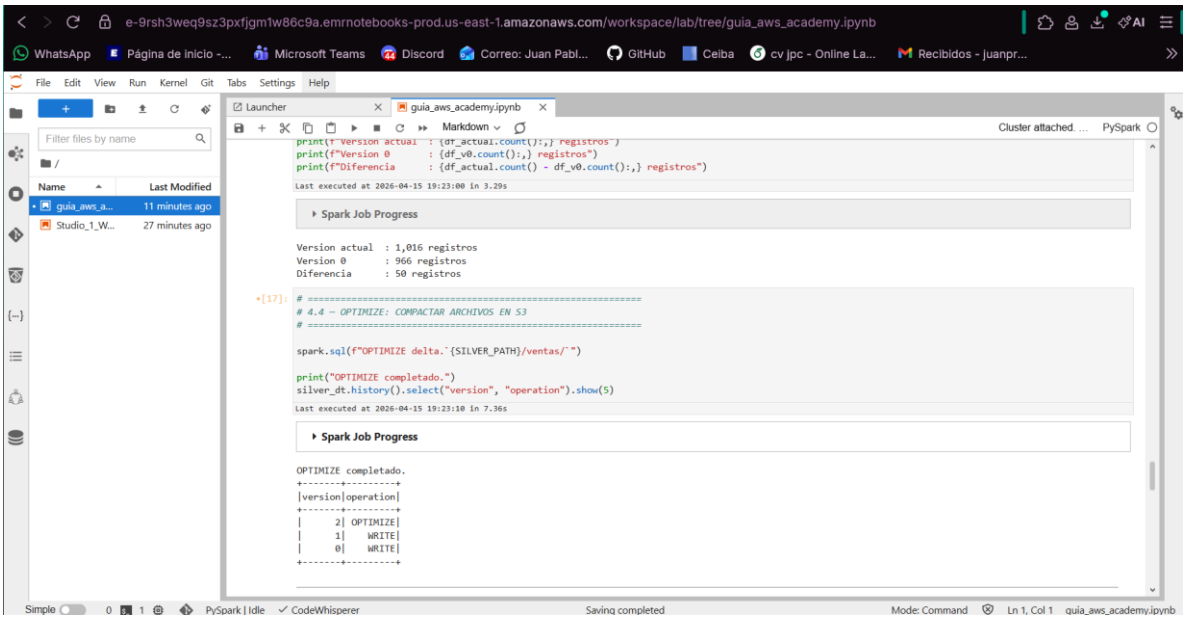

Ejercicios

#1

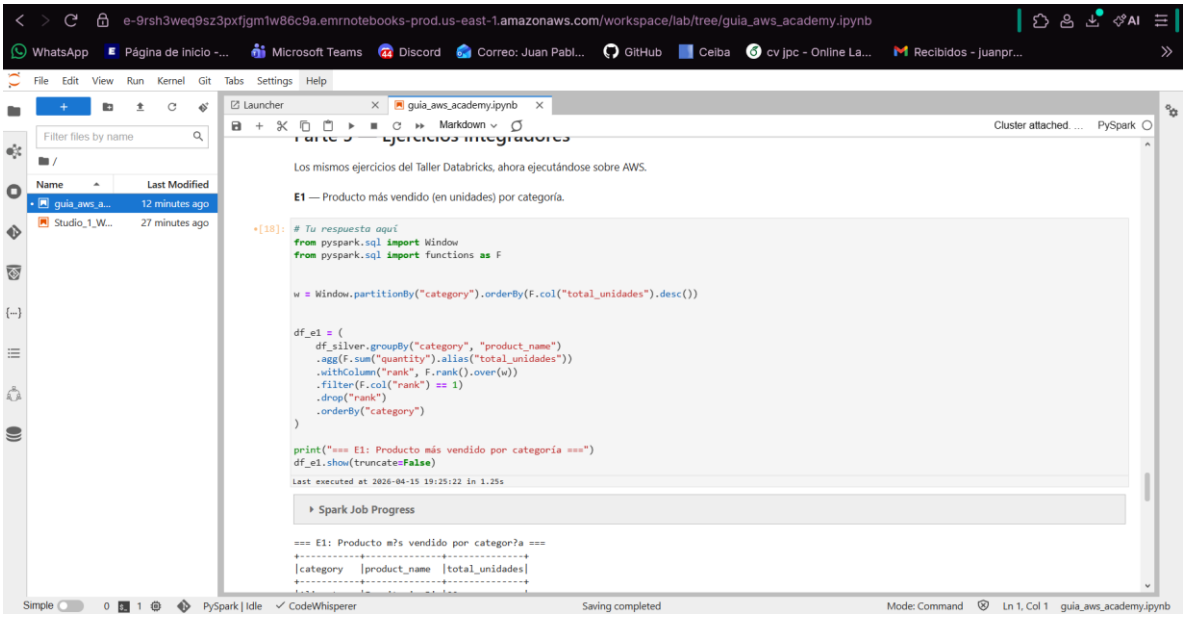

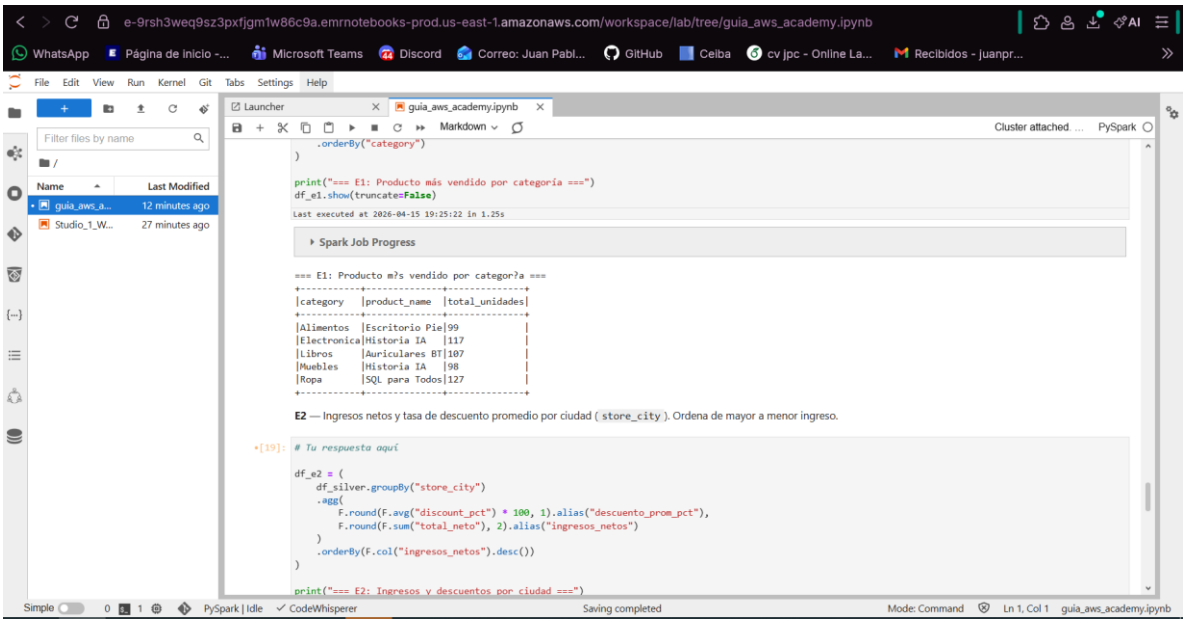
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Name
Last Modified
guia_aws_a...
12 minutes ago
Studio_1_W...
27 minutes ago
.orderBy("category")
)
print("=== E1: Producto más vendido por categoría ===")
df_e1.show(truncate=False)
Last executed at 2026-04-15 19:25:22 in 1.25s
Spark Job Progress
=== E1: Producto m?s vendido por categor?a ===
+-----------+--------------+--------------+
|category |product_name |total_unidades|
+-----------+--------------+--------------+
Alimentos	Escritorio Pie	99
Electronica	Historia IA	117
Libros	Auriculares BT	107
Muebles	Historia IA	98
Ropa	SQL para Todos	127
+-----------+--------------+--------------+
E2 — Ingresos netos y tasa de descuento promedio por ciudad (store_city). Ordena de mayor a menor ingreso.
[19]:
# Tu respuesta aquí
df_e2 = (
df_silver.groupBy("store_city")
.agg(
F.round(F.avg("discount_pct") * 100, 1).alias("descuento_prom_pct"),
F.round(F.sum("total_neto"), 2).alias("ingresos_netos")
)
.orderBy(F.col("ingresos_netos").desc())
)
print("=== E2: Ingresos y descuentos por ciudad ===")
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

#2

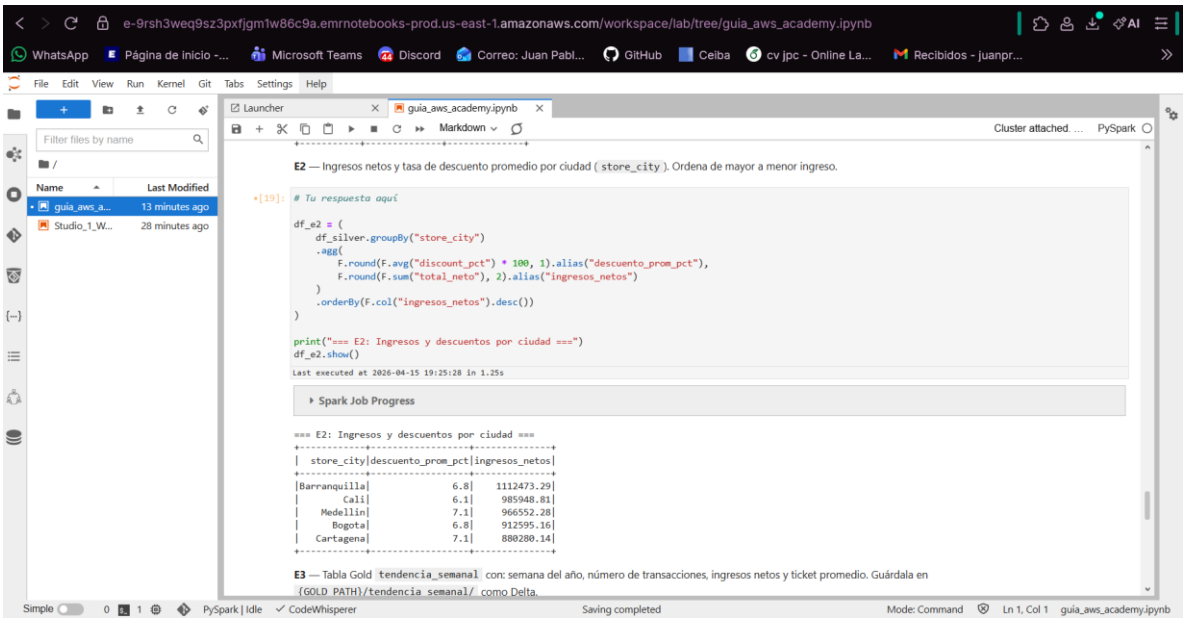
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Name
Last Modified
guia_aws_a...
13 minutes ago
Studio_1_W...
28 minutes ago
E2 — Ingresos netos y tasa de descuento promedio por ciudad (store_city). Ordena de mayor a menor ingreso.
[19]:
# Tu respuesta aquí
df_e2 = (
df_silver.groupBy("store_city")
.agg(
F.round(F.avg("discount_pct") * 100, 1).alias("descuento_prom_pct"),
F.round(F.sum("total_neto"), 2).alias("ingresos_netos")
)
.orderBy(F.col("ingresos_netos").desc())
)
print("=== E2: Ingresos y descuentos por ciudad ===")
df_e2.show()
Last executed at 2026-04-15 19:25:28 in 1.25s
Spark Job Progress
=== E2: Ingresos y descuentos por ciudad ===
+------------+------------------+---------------+
| store_city|descuento_prom_pct|ingresos_netos|
+------------+------------------+---------------+
|Barranquilla| 6.8| 1112473.29|
Cali	6.1	985948.81
Medellin	7.1	966552.28
Bogota	6.8	912595.16
Cartagena	7.1	880280.14
+------------+------------------+---------------+
E3 — Tabla Gold tendencia_semanal con: semana del año, número de transacciones, ingresos netos y ticket promedio. Guárdala en
{GOLD_PATH}/tendencia_semanal/ como Delta.
Simple
PySpark | Idle
CodeWhisperer
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

#3

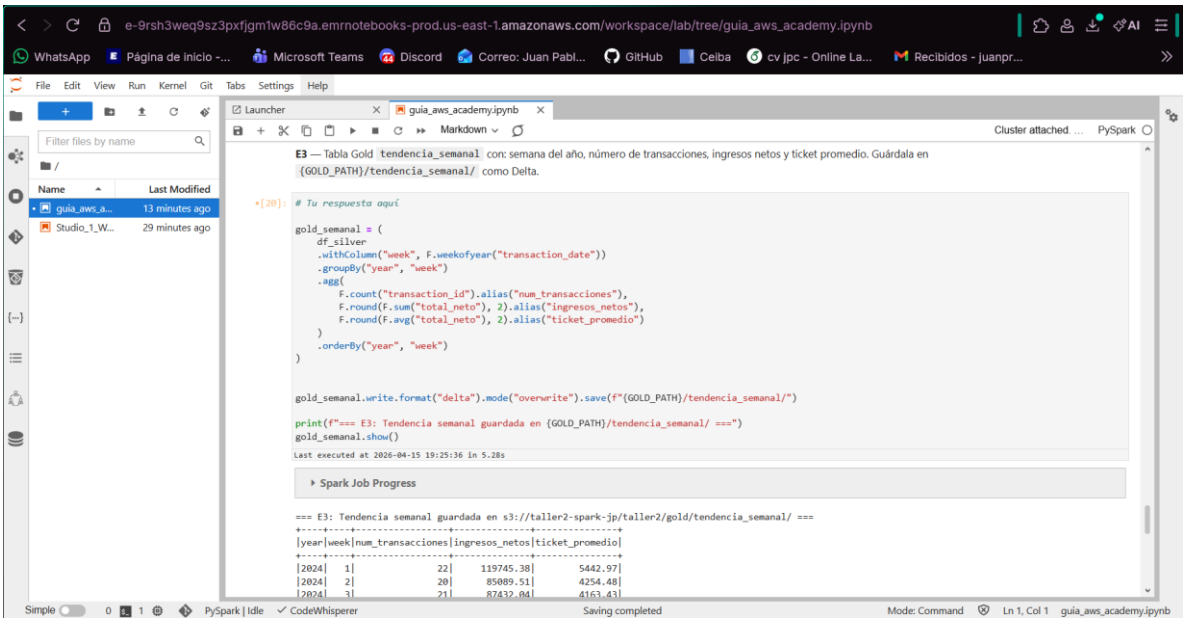
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
E3 — Tabla Gold tendencia_semanal con: semana del año, número de transacciones, ingresos netos y ticket promedio. Guárdala en {GOLD_PATH}/tendencia_semanal/ como Delta.
*[20]:
# Tu respuesta aquí
gold_semanal = (
df_silver
.withColumn("week", F.weekofyear("transaction_date"))
.groupBy("year", "week")
.agg(
F.count("transaction_id").alias("num_transacciones"),
F.round(F.sum("total_neto"), 2).alias("ingresos_netos"),
F.round(F.avg("total_neto"), 2).alias("ticket_promedio")
)
.orderBy("year", "week")
)
gold_semanal.write.format("delta").mode("overwrite").save(f"{GOLD_PATH}/tendencia_semanal/")
print(f"=== E3: Tendencia semanal guardada en {GOLD_PATH}/tendencia_semanal/ ===")
gold_semanal.show()
Last executed at 2026-04-15 19:25:36 in 5.28s
Spark Job Progress
=== E3: Tendencia semanal guardada en s3://taller2-spark-jp/taller2/gold/tendencia_semanal/ ===
+----+----+----------------+--------------+----------------+
|year|week|num_transacciones|ingresos_netos|ticket_promedio|
+----+----+----------------+--------------+----------------+
|2024| 1| 22| 119745.38| 5442.97|
|2024| 2| 20| 85089.51| 4254.48|
|2024| 3| 21| 87432.04| 4163.43|
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

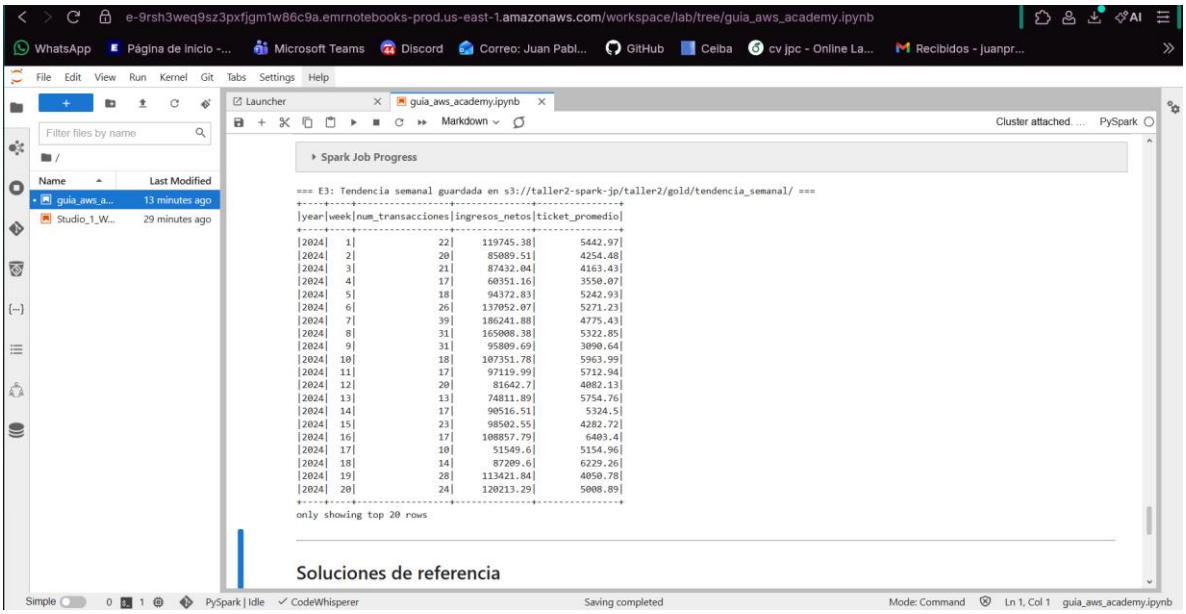
e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb
File Edit View Run Kernel Git Tabs Settings Help
Launcher
guia_aws_academy.ipynb
Markdown
Cluster attached. ...
PySpark
Spark Job Progress
=== E3: Tendencia semanal guardada en s3://taller2-spark-jp/taller2/gold/tendencia_semanal/ ===
+----+----+----------------+--------------+----------------+
|year|week|num_transacciones|ingresos_netos|ticket_promedio|
+----+----+----------------+--------------+----------------+
|2024| 1| 22| 119745.38| 5442.97|
|2024| 2| 20| 85089.51| 4254.48|
|2024| 3| 21| 87432.04| 4163.43|
|2024| 4| 17| 60351.16| 3550.07|
|2024| 5| 18| 94372.83| 5242.93|
|2024| 6| 26| 137052.07| 5271.23|
|2024| 7| 39| 186241.88| 4775.43|
|2024| 8| 31| 165008.38| 5322.85|
|2024| 9| 31| 95809.69| 3090.64|
|2024| 10| 18| 107351.78| 5963.99|
|2024| 11| 17| 97119.99| 5712.94|
|2024| 12| 20| 81642.7| 4082.13|
|2024| 13| 13| 74811.89| 5754.76|
|2024| 14| 17| 90516.51| 5324.5|
|2024| 15| 23| 98502.55| 4282.72|
|2024| 16| 17| 108857.79| 6403.4|
|2024| 17| 10| 51549.6| 5154.96|
|2024| 18| 14| 87209.6| 6229.26|
|2024| 19| 28| 113421.84| 4050.78|
|2024| 20| 24| 120213.29| 5008.89|
+----+----+----------------+--------------+----------------+
only showing top 20 rows
Soluciones de referencia
Saving completed
Mode: Command
Ln 1, Col 1
guia_aws_academy.ipynb

Limpieza

e-9rsh3weq9sz3pxfjgm1w86c9a.emrnotebooks-prod.us-east-1.amazonaws.com/workspace/lab/tree/guia_aws_academy.ipynb

Limpieza de recursos

Importante: para preservar tus créditos del Learner Lab, termina el cluster cuando termines el taller.

```
# Eliminar datos del taller del bucket S3
result = subprocess.run(
    ["aws", "s3", "rm", f"s3://{BUCKET_NAME}/taller2/", "--recursive"],
    capture_output=True, text=True
)
print(f"Datos eliminados de s3://{BUCKET_NAME}/taller2/")
```

Last executed at 2026-04-15 19:41:16 in 743ms

```
Datos eliminados de s3://taller2-spark-jp/taller2/
```

Terminar el cluster de EMR

1. Ve a la consola de AWS → **EMR** → **Clusters**
2. Selecciona `taller2-cluster`
3. Haz clic en **"Terminate"** y confirma

> Un cluster en estado **"Waiting"** sigue consumiendo créditos aunque no esté procesando datos.

Pausar el Learner Lab (si ya no vas a continuar)

1. Regresa al portal de AWS Academy
2. Haz clic en **"End Lab"** para pausar el entorno y detener el consumo de créditos